

Principi di Inferenza

Statistica descrittiva: Indici di variabilità

Laura D'Angelo
Università Milano Bicocca

Gli **indici di variabilità** (o di dispersione) sono singoli valori di sintesi che descrivono “quanto sono diversi” i dati tra loro.

Vedremo:

- ▶ **intervalli di variazione:** range, range interquartile;
- ▶ **varianza**, deviazione standard;
- ▶ **coefficiente di variazione.**

Ci occuperemo solo di indici di variabilità per **variabili quantitative** (discrete o continue).

1

Intervalli di variazione

Consideriamo $x_1, \dots, x_n$ i dati osservati di una variabile quantitativa X .

Inoltre, indichiamo con $x_{(1)} \leq x_{(2)} \leq \dots \leq x_{(n)}$ i dati ordinati, così che $x_{(i)}$ indica l' i -esimo valore osservato in ordine (crescente) di grandezza.

► **Range:** $x_{(n)} - x_{(1)}$

Ovvero, la distanza tra il valore più grande e il più piccolo osservato.

► **Range interquartile:** $IQR = q_{0.75} - q_{0.25}$

Anche detto *distanza* o *differenza* interquartile.

Misura la variabilità del 50% centrale dei dati (è quello che abbiamo usato per costruire il boxplot).

— più adatto in presenza di **valori anomali**.

2

Varianza e deviazione standard

Consideriamo $x_1, \dots, x_n$ i dati osservati di una variabile quantitativa X .

Definiamo prima alcune quantità che ci serviranno per calcolarla:

- **Scostamenti dalla media:**

$$|x_i - \bar{x}| \quad \text{per } i = 1, \dots, n$$

ovvero, per ciascuna osservazione $i = 1, \dots, n$, calcoliamo **quanto** x_i è “lontana” dalla media $\bar{x}$.
Non ci interessa il segno, prendiamo il valore assoluto.

- **Scostamenti quadratici:**

$$(x_i - \bar{x})^2 \quad \text{per } i = 1, \dots, n$$

- La **varianza** è la **media degli scostamenti quadratici** ed è la misura di variabilità più utilizzata.

Definizione

Date le osservazioni $x_1, \dots, x_n$ di una variabile X , la **varianza** è

$$\text{var}(X) = \sigma^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2$$

Abbiamo definito la varianza come $\sigma^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2$

- Se la varianza è **grande** significa che, **in media**, i dati sono distanti dalla loro media $\bar{x}$ (e quindi, sono distanti uno dall'altro).

Se la varianza è **piccola** significa che, **in media**, i dati sono vicini alla media $\bar{x}$.

- La varianza è $\sigma^2 \geq 0$ (non-negativa).

Vale $\sigma^2 = 0$ se e solo se $x_i = a$ per ogni $i = 1, \dots, n$ (ovvero se i dati sono tutti uguali).

- La **varianza di una trasformazione lineare**, definita come $Y = aX + b$, con $a, b \in \mathbb{R}$, è

$$\text{var}(Y) = a^2 \text{var}(X)$$

- La varianza ha una **formula alternativa** (più semplice ai fini del calcolo):

$$\sigma^2 = \underbrace{\left(\frac{1}{n} \sum_{i=1}^n x_i^2 \right)}_{\text{la media dei quadrati}} - \underbrace{\bar{x}^2}_{\text{il quadrato della media}}$$

Esercizio Si calcoli la varianza dei seguenti dati usando entrambe le formule:

$$(1, 3, 2, 5)$$

Primo approccio: $\sigma^2 = \frac{1}{n} \sum_{i=1}^4 (x_i - \bar{x})$

► Dobbiamo intanto calcolare la media $\bar{x} = \frac{1 + 3 + 2 + 5}{4} = 2.75$

► Calcoliamo gli scostamenti di ciascun valore da $\bar{x}$:

$$|1 - 2.75| = 1.75, \quad |3 - 2.75| = 0.25, \quad |2 - 2.75| = 0.75, \quad |5 - 2.75| = 2.25$$

► Prendiamo i quadrati di ciascuno scostamento:

$$(1 - 2.75)^2 = 3.0625, \quad (3 - 2.75)^2 = 0.0625, \quad (2 - 2.75)^2 = 0.5625, \quad (5 - 2.75)^2 = 5.0625$$

► Otteniamo la varianza come media degli scostamenti quadratici:

$$\sigma^2 = \frac{3.0625 + 0.0625 + 0.5625 + 5.0625}{4} = 2.1875$$

Esercizio Si calcoli la varianza dei seguenti dati usando entrambe le formule:

$$(1, 3, 2, 5)$$

Secondo approccio: $\sigma^2 = \left(\frac{1}{n} \sum_{i=1}^n x_i^2\right) - \bar{x}^2$

- Calcoliamo il quadrato delle osservazioni:

$$1^2 = 1, \quad 3^2 = 9, \quad 2^2 = 4, \quad 5^2 = 25$$

- Facciamo la media dei quadrati:

$$\frac{1}{n} \sum_{i=1}^n x_i^2 = \frac{1 + 9 + 4 + 25}{4} = 9.75$$

- Calcoliamo il quadrato della media $\bar{x}$ (già calcolata sopra): $\bar{x}^2 = 2.75^2 = 7.5625$
- Calcoliamo la varianza come differenza tra le due quantità appena calcolate:

$$\sigma^2 = 9.75 - 7.5625 = 2.1875$$

Definizione

La **deviazione standard** (anche detta scarto quadratico medio) è la radice quadrata della varianza:

$$\sigma = \text{sd}(X) = \sqrt{\sigma^2}$$

- ▶ La deviazione standard ha la **stessa unità di misura delle osservazioni** (al contrario della varianza, che ha come unità di misura il quadrato dell'unità di misura delle osservazioni).
- ▶ Si interpreta in modo analogo alla varianza: valori grandi indicano osservazioni molto diverse tra loro, valori piccoli indicano osservazioni simili tra loro.
- ▶ Anche per la deviazione standard vale $\sigma \geq 0$; dove $\sigma = 0$ se e solo se le osservazioni sono costanti.
- ▶ Se una distribuzione di dati ha media $\bar{x}$ e deviazione standard σ , allora:
 - ▶ almeno il 75% dei dati si trova nell'intervallo $[\bar{x} - 2\sigma, \bar{x} + 2\sigma]$
 - ▶ almeno l' 88% dei dati si trova nell'intervallo $[\bar{x} - 3\sigma, \bar{x} + 3\sigma]$
 - ▶ almeno il 93% dei dati si trova nell'intervallo $[\bar{x} - 4\sigma, \bar{x} + 4\sigma]$

3

Coefficiente di variazione

Abbiamo visto che:

- ▶ la deviazione standard ha la stessa unità di misura delle osservazioni,
- ▶ la varianza ha come unità di misura il quadrato dell'unità di misura delle osservazioni.

Se vogliamo confrontare distribuzioni diverse, che hanno unità di misura diverse, questi indici non sono confrontabili (esempio: vogliamo confrontare i salari italiani in Euro con i salari norvegesi in Corone).

Il **coefficiente di variazione** è un indice di dispersione **utile per confrontare distribuzioni diverse**, perchè **non ha unità di misura**.

Definizione

Date le osservazioni $x_1, \dots, x_n$ di una variabile X , il **coefficiente di variazione** è

$$cv(X) = \frac{\sigma}{|\bar{x}|}$$

ovvero il rapporto tra la deviazione standard di X e il valore assoluto della sua media aritmetica.