Principi di Inferenza

Introduzione all'inferenza

Laura D'Angelo
Università Milano Bicocca

Cos'è l'inferenza?

- La **popolazione** è l'insieme di tutte le unità statistiche.
  Nota: quali sono le unità statistiche dipende dalla domanda di ricerca.

  Esempio: siamo interessati all'altezza media della popolazione italiana al 1/10/2026.
  Popolazione: la popolazione italiana al 1/10/2026.
  Obiettivo: conoscere l'altezza media μ

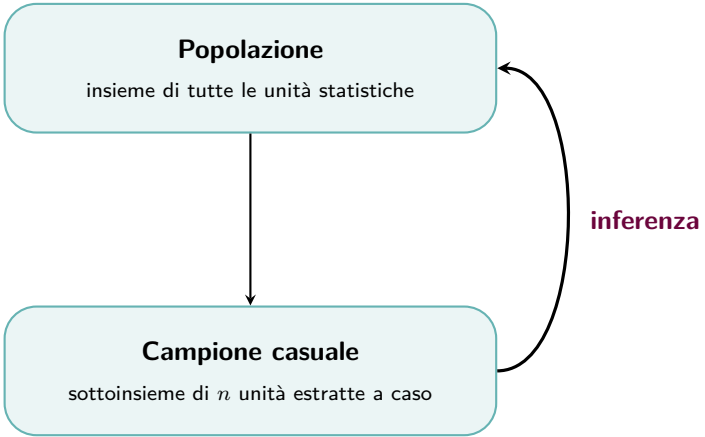
- Tuttavia, raccogliere l'informazione sull'altezza per ogni individuo nella popolazione è complicato e/o molto costoso. Per questo motivo, **estraiamo casualmente n persone** dalla popolazione.

- Un **campione casuale** è un sottoinsieme della popolazione estratto a caso.
  Sul campione, **registriamo la variabile di interesse sugli n individui** estratti.

  Esempio: registriamo
  x_1 = altezza del primo individuo nel campione,
  x_2 = altezza del secondo individuo nel campione,
  $\vdots$
  x_n = altezza dell'n-esimo individuo nel campione,

→ **Inferenza**: **cosa possiamo concludere sulla popolazione guardando solo il campione?**

Il meccanismo dell'inferenza



Il campione

- Una volta estratto il campione, ma **prima di osservare la variabile di interesse sui soggetti estratti**, definiamo
  - X_1 = variabile aleatoria che descrive l'altezza del primo individuo nel campione
  - X_2 = variabile aleatoria che descrive l'altezza del secondo individuo nel campione
  - $\vdots$
  - X_n = variabile aleatoria che descrive l'altezza dell'n-esimo individuo nel campione,

  $\Rightarrow (X_1, X_2, \ldots, X_n)$ sono le variabili aleatorie che (prima di osservare il campione), modellano l'incertezza dell'esito

- Il numero n è detto numerosità campionaria

- **Una volta registrate le osservazioni**, $(x_1, x_2, \ldots, x_n)$ sono i valori/numeri osservati (ovvero i dati, non sono più variabili aleatorie, sono le loro realizzazioni)

  Sui dati, possiamo calcolare $\bar{x} = n^{-1} \sum_{i=1}^{n} x_i$, valore della media campionaria nel campione estratto; oppure $\mathrm{var}(x) = n^{-1} \sum_{i=1}^{n} (x_i - \bar{x})^2$, valore della varianza nel campione estratto, o altre quantità.

1 Inferenza sulla media

Media Campionaria

Consideriamo una popolazione e una variabile misurata su questa popolazione.

- Sia μ la media in popolazione
- Sia σ^2 la varianza in popolazione

(in genere non conosciamo μ e σ^2 e vogliamo stimarli).

Sia $(x_1, x_2, \ldots, x_n)$ un campione casuale $\Rightarrow$ in questo caso stiamo assumendo $X_i \perp X_j$ per $i \neq j$ (le variabili aleatorie corrispondenti a individui diversi sono indipendenti). Inoltre, assumiamo anche che le variabili siano identicamente distribuite.
Prima di osservare il campione, abbiamo n variabili aleatorie indipendenti e identicamente distribuite $(X_1, X_2, \ldots, X_n)$, con media μ e varianza σ^2.

A partire da $(X_1, X_2, \ldots, X_n)$ possiamo calcolare una nuova variabile aleatoria:

$$\bar{X} = \frac{1}{n} \sum_{i=1}^{n} X_i$$

Si può dimostrare che

$$E[\bar{X}] = \mu \qquad \text{var}(\bar{X}) = \frac{\sigma^2}{n}$$

Esempio (popolazione immaginaria)

Campione di numerosità $n = 1$

Domanda di ricerca: vogliamo conoscere il numero medio di figli in una popolazione di genitori.

In questa popolazione immaginaria, metà dei genitori ha 1 figlio e l'altra metà 2 figli.
Quindi $\mu = 1.5$ (media "vera" nella popolazione - nella pratica non abbiamo questa informazione)

- Estraiamo un campione casuale di numerosità $n = 1$:
  Prima di osservare il dato, abbiamo una variabile aleatoria
  $X_1 =$"numero di figli della prima unità statistica"
  X_1 può assumere i valori 1 o 2: in particolare, la distribuzione di probabilità è

$$P(X_1 = 1) = 0.5$$
$$P(X_1 = 2) = 0.5$$

- Possiamo calcolare il valore atteso e varianza di questa variabile aleatoria:

$$E[X_1] = 1 \times 0.5 + 2 \times 0.5 = 1.5 \qquad \text{dove è centrata?}$$
$$\text{var}(X_1) = E[X_1^2] - E[X_1]^2 = 1^2 \times 0.5 + 2^2 \times 0.5 - 1.5^2 = 0.25 \qquad \text{quanta incertezza c'è?}$$

Esempio (popolazione immaginaria)

Campione di numerosità $n = 2$

- Sulla stessa popolazione, estraiamo ora un campione casuale di numerosità $n = 2$

  Abbiamo quindi due variabili aleatorie **indipendenti**: X_1 e X_2

  Quali valori può assumere la coppia (X_1, X_2)? Con quale probabilità?

Possibili valori:	$(1,1)$	$(1,2)$	$(2,1)$	$(2,2)$
Probabilità:	0.5^2	0.5^2	0.5^2	0.5^2
Media campionaria:	1	1.5	1.5	2

- Possiamo studiare una nuova variabile aleatoria: la media campionaria tra X_1 e X_2, ovvero $\bar{X}$.

  Che distribuzione di probabilità ha $\bar{X}$? È precisamente quella scritta in tabella, ovvero:

$$P(\bar{X} = 1) = P(X_1 = 1, X_2 = 1) = 0.5^2 = 0.25$$
$$P(\bar{X} = 1.5) = P((X_1 = 1, X_2 = 2) \cup (X_1 = 2, X_2 = 1)) = 0.5^2 + 0.5^2 = 0.5$$
$$P(\bar{X} = 2) = P(X_1 = 2, X_2 = 2) = 0.5^2 = 0.25$$

- Possiamo calcolare il valore atteso e varianza di $\bar{X}$:

$$E[\bar{X}] = 1 \times 0.25 + 1.5 \times 0.5 + 2 \times 0.25 = 1.5$$
$$\text{var}(\bar{X}) = E[\bar{X}^2] - E[\bar{X}]^2 = 0.125$$

- Estraiamo un campione casuale di numerosità $n = 3$.
  Abbiamo tre variabili aleatorie indipendenti (X_1, X_2, X_3)

Valori possibili	Probabilità	Media campionaria
$(1, 1, 1)$	$0.5^3 = 0.125$	1
$(1, 1, 2)$	0.125	1.33
$(1, 2, 1)$	0.125	1.33
$(1, 2, 2)$	0.125	1.67
$(2, 1, 1)$	0.125	1.33
$(2, 1, 2)$	0.125	1.67
$(2, 2, 1)$	0.125	1.67
$(2, 2, 2)$	0.125	2

Distribuzione della media campionaria ($n = 3$)

- Possiamo studiare la variabile aleatoria media campionaria tra X_1, X_2 e X_3, ovvero $\bar{X}$. La sua distribuzione di probabilità è

Valori di $\bar{X}$	Probabilità
1	0.125
1.33	0.375
1.67	0.375
2	0.125

- Il valore atteso e varianza di $\bar{X}$ in questo caso sono:

$$E[\bar{X}] = 1 \times 0.125 + 1.33 \times 0.375 + 1.67 \times 0.375 + 2 \times 0.125 = 1.5$$
$$\text{var}(\bar{X}) = E[\bar{X}^2] - E[\bar{X}]^2 \approx 0.083$$

Lo stimatore $\bar{X}$

Il valore atteso di $\bar{X}$ è il valore μ a cui siamo interessati.

$$E[\bar{X}] = \mu$$

Più alta la numerosità campionaria, meno incertezza:

$$\text{var}(\bar{X}) \underset{n\to\infty}{\to} 0$$

La variabile aleatoria $\bar{X}$ è uno **stimatore** per μ: una variabile aleatoria funzione di $(X_1, \ldots, X_n)$.

$\bar{x}$ = valore dello stimatore nel campione *osservato* è la **stima**.

- $\bar{X}$ è uno stimatore non distorto per μ: $E[\bar{X}] = \mu$
- $\bar{X}$ è uno stimatore consistente per μ: $\text{var}(\bar{X}) \to 0$ per $n \to \infty$

2 Inferenza sulla varianza

La varianza di popolazione

Consideriamo una popolazione e una variabile misurata su questa popolazione.

- μ = media in popolazione
- σ^2 = varianza in popolazione, ovvero

$$\sigma^2 = \mathrm{E}\big[(X-\mu)^2\big]$$

Obiettivo: stimare σ^2 a partire da $(X_1, \ldots, X_n)$, con X_i indipendenti e identicamente distribuite.

Idea naturale: sostituire il valore atteso con la media campionaria (come abbiamo fatto per l'inferenza sulla media).

$$\sigma^2 = \mathrm{E}\big[(X-\mu)^2\big] \quad \longrightarrow \quad \frac{1}{n}\sum_{i=1}^{n}(X_i-\mu)^2$$

Ma questo richiede di conoscere μ. Distinguiamo due casi:

1. **media μ nota** (raro, ma utile per capire);
2. **media μ non nota** (il caso tipico): dovremo usare $\bar{X}$ al posto di μ.

Stimatore della varianza con media nota

Supponiamo di conoscere μ. Definiamo lo stimatore

$$S_0^2 = \frac{1}{n}\sum_{i=1}^{n}(X_i - \mu)^2$$

Osserviamo che, posto $Y_i = (X_i - \mu)^2$, abbiamo $S_0^2 = \bar{Y}$: è una media campionaria di variabili aleatorie indipendenti, con

$$\mathrm{E}[Y_i] = \mathrm{E}[(X_i - \mu)^2] = \sigma^2$$

Proprietà dello stimatore S_0^2

Non distorsione: per linearità del valore atteso

$$\mathrm{E}[S_0^2] = \frac{1}{n}\sum_{i=1}^{n}\mathrm{E}[Y_i] = \frac{1}{n}\sum_{i=1}^{n}\mathrm{E}[(X_i-\mu)^2] = \frac{1}{n}\cdot n\sigma^2 = \sigma^2$$

Consistenza: le $Y_i = (X_i-\mu)^2$ sono indipendenti e identicamente distribuite, quindi

$$\mathrm{var}(S_0^2) = \mathrm{var}(\bar{Y}) = \frac{\mathrm{var}\big((X-\mu)^2\big)}{n} \underset{n\to\infty}{\longrightarrow} 0$$

(se $\mathrm{var}((X-\mu)^2) < \infty$).

Conclusione

Con media nota, S_0^2 è uno stimatore non distorto e consistente per σ^2. È esattamente lo stesso risultato visto per $\bar{X}$ con μ, applicato alle variabili $Y_i = (X_i-\mu)^2$.

Stimatore della varianza con media non nota

Se μ non è nota, non possiamo calcolare $(X_i - \mu)$. Sostituiamo μ con il suo stimatore $\bar{X}$:

$$S^2 = \frac{1}{n}\sum_{i=1}^{n}(X_i - \bar{X})^2$$

Domanda: S^2 è ancora non distorto per σ^2?

Intuizione: $\bar{X}$ è calcolata *sugli stessi dati*, quindi è "più vicina" ai dati di quanto lo sia μ:

$$\sum_{i=1}^{n}(X_i - \bar{X})^2 \;\leq\; \sum_{i=1}^{n}(X_i - \mu)^2$$

Ci aspettiamo che S^2 tenda a sottostimare σ^2. Verifichiamolo con un esempio.

Domanda di ricerca: vogliamo conoscere la variabilità di una certa variabile X in una popolazione.

In questa popolazione immaginaria, X assume i valori 1, 2, 3, ciascuno per un terzo delle unità:

$$P(X = 1) = P(X = 2) = P(X = 3) = \tfrac{1}{3}$$

Quindi i valori "veri" (nella pratica non li conosciamo) sono

$$\mu = 1 \times \tfrac{1}{3} + 2 \times \tfrac{1}{3} + 3 \times \tfrac{1}{3} = 2$$
$$\sigma^2 = (1-2)^2 \times \tfrac{1}{3} + (2-2)^2 \times \tfrac{1}{3} + (3-2)^2 \times \tfrac{1}{3} = \tfrac{2}{3} \approx 0.67$$

Estraiamo campioni casuali di numerosità n piccola e studiamo la distribuzione di S^2.

Esempio (media non nota)

Campione di numerosità $n = 1$

- Con $n = 1$ abbiamo $\bar{X} = X_1$, quindi

$$S^2 = (X_1 - \bar{X})^2 = 0 \quad \text{sempre}$$

- Il valore atteso è

$$\mathrm{E}[S^2] = 0 \neq \sigma^2 = \tfrac{2}{3}$$

- Il risultato è ovvio: con una sola osservazione non abbiamo alcuna informazione sulla variabilità.

Con $n = 2$ le cose vanno meglio, ma qualcosa non torna ancora...

Esempio (media non nota)

Campione di numerosità $n = 2$

(X_1, X_2)	Prob.	$\bar{X}$	S^2
$(1,1)$	$1/9$	1	0
$(1,2)$	$1/9$	1.5	0.25
$(1,3)$	$1/9$	2	1
$(2,1)$	$1/9$	1.5	0.25
$(2,2)$	$1/9$	2	0
$(2,3)$	$1/9$	2.5	0.25
$(3,1)$	$1/9$	2	1
$(3,2)$	$1/9$	2.5	0.25
$(3,3)$	$1/9$	3	0

Distribuzione di S^2:

Valori di S^2	Probabilità
0	$3/9$
0.25	$4/9$
1	$2/9$

$$\mathrm{E}[S^2] = 0.25 \times \tfrac{4}{9} + 1 \times \tfrac{2}{9} = \tfrac{1}{3}$$

Confronto: $\sigma^2 = \frac{2}{3}$.

In media S^2 vale la metà di σ^2: $\mathrm{E}[S^2] = \frac{n-1}{n}\,\sigma^2$ con $n = 2$.

Distorsione di S^2

Si può dimostrare che, per ogni n,

$$\mathrm{E}[S^2] = \frac{n-1}{n}\,\sigma^2 \qquad \Longrightarrow \qquad \text{distorsione} = \mathrm{E}[S^2] - \sigma^2 = -\frac{\sigma^2}{n}$$

Dimostrazione. Sommando e sottraendo μ si ottiene la scomposizione

$$\sum_{i=1}^{n}(X_i - \bar{X})^2 = \sum_{i=1}^{n}(X_i - \mu)^2 - n(\bar{X} - \mu)^2$$

Prendendo il valore atteso, e ricordando che $\mathrm{E}[(\bar{X} - \mu)^2] = \mathrm{var}(\bar{X}) = \sigma^2/n$,

$$\mathrm{E}\Big[\sum_{i=1}^{n}(X_i - \bar{X})^2\Big] = n\sigma^2 - n \cdot \frac{\sigma^2}{n} = (n-1)\sigma^2$$

Dividendo per n si ottiene il risultato.

- S^2 è distorto (per difetto) ma la distorsione $\to 0$ per $n \to \infty$: è asintoticamente non distorto.
- Abbiamo "pagato" per aver stimato μ con $\bar{X}$: i dati ci servono prima per stimare μ e poi per stimare σ^2.

La correzione: la varianza campionaria corretta

Poiché $\mathrm{E}[S^2] = \frac{n-1}{n}\sigma^2$, moltiplichiamo per $\frac{n}{n-1}$:

$$S_c^2 = \frac{n}{n-1}\,S^2 = \frac{1}{n-1}\sum_{i=1}^{n}(X_i - \bar{X})^2 \qquad \Longrightarrow \qquad \mathrm{E}[S_c^2] = \sigma^2$$

Sull'esempio con $n = 2$, $S_c^2 = 2S^2$:

Valori di S_c^2	Probabilità
0	$3/9$
0.5	$4/9$
2	$2/9$

$$\mathrm{E}[S_c^2] = 0.5 \times \tfrac{4}{9} + 2 \times \tfrac{2}{9} = \tfrac{2}{3} = \sigma^2 \qquad \checkmark$$

Riassunto: stimatori della varianza

	Media nota	**Media non nota**	
Stimatore	$S_0^2 = \frac{1}{n}\sum(X_i - \mu)^2$	$S^2 = \frac{1}{n}\sum(X_i - \bar{X})^2$	$S_c^2 = \frac{1}{n-1}\sum(X_i - \bar{X})^2$
$\mathrm{E}[\cdot]$	σ^2	$\frac{n-1}{n}\sigma^2$	σ^2
Non distorto	sì	no (asint. sì)	sì
Consistente	sì	sì	sì

- Con μ nota si divide per n; con μ stimata da $\bar{X}$ si divide per $n-1$ per compensare la perdita di un grado di libertà.
- Per n grande la differenza tra S^2 e S_c^2 è trascurabile (fattore $\frac{n}{n-1} \to 1$).

3 Quanto è buono uno stimatore?

Proprietà di uno stimatore

Sia $\hat{\Theta}$ uno stimatore di un parametro θ (per esempio: $\theta = \mu$ o $\theta = \sigma^2$). Possiamo calcolare:

- **Distorsione**: $\mathrm{Bias}(\hat{\Theta}) = \mathrm{E}[\hat{\Theta}] - \theta$
- **Errore standard**: $\mathrm{SE}(\hat{\Theta}) = \sqrt{\mathrm{var}(\hat{\Theta})}$, la fluttuazione di $\hat{\Theta}$ intorno al suo valore atteso
- **Errore quadratico medio** (mean squared error):

$$\mathrm{MSE}(\hat{\Theta}) = \mathrm{E}\left[(\hat{\Theta} - \theta)^2\right] = \mathrm{var}(\hat{\Theta}) + \mathrm{Bias}(\hat{\Theta})^2$$

Per $\bar{X}_n$: $\mathrm{Bias} = 0$, $\mathrm{SE}(\bar{X}_n) = \dfrac{\sigma}{\sqrt{n}}$, $\mathrm{MSE}(\bar{X}_n) = \dfrac{\sigma^2}{n}$.

Consistenza

$\hat{\Theta}_n$ è consistente se

$$\hat{\Theta}_n \to \theta \qquad \text{in probabilità.}$$

Condizione sufficiente: distorsione e varianza tendono entrambe a zero, ovvero $\mathrm{MSE}(\hat{\Theta}_n) \to 0$.

Non distorto non significa necessariamente "migliore"

Confronto tra S^2 e S_c^2 (popolazione normale)

Se $X_i \sim \mathcal{N}(\mu, \sigma^2)$, si possono dimostrare le seguenti proprietà:

	Bias	var	MSE
$S_c^2 = \frac{1}{n-1}\sum(X_i - \bar{X}_n)^2$	0	$\dfrac{2\sigma^4}{n-1}$	$\dfrac{2\sigma^4}{n-1}$
$S^2 = \frac{1}{n}\sum(X_i - \bar{X}_n)^2$	$-\dfrac{\sigma^2}{n}$	$\dfrac{2(n-1)\sigma^4}{n^2}$	$\dfrac{(2n-1)\sigma^4}{n^2}$

Per ogni $n \geq 2$ vale $\dfrac{2n-1}{n^2} < \dfrac{2}{n-1}$: lo stimatore distorto S^2 ha MSE minore.

Ad esempio, con $n = 10$: $\mathrm{MSE}(S^2) = 0.19\,\sigma^4$ contro $\mathrm{MSE}(S_c^2) = 0.22\,\sigma^4$.

- Rinunciare alla non-distorsione può ridurre la varianza abbastanza da guadagnare in MSE: **compromesso distorsione-varianza** (*bias-variance tradeoff*).
- S_c^2 resta lo standard perché è non distorto, ma il criterio "giusto" dipende dall'obiettivo.
- Nella parte sulla verosimiglianza vedremo un criterio più generale (*efficienza*).