Principi di Inferenza

Teorema del limite centrale e inferenza sulla media

Laura D'Angelo
Università Milano Bicocca

Argomenti della lezione

- **Distribuzione campionaria e TLC**: com'è fatta la distribuzione di $\bar{X}_n$?
- **Metodi dell'inferenza statistica**: intervalli di confidenza e verifica di ipotesi;
- **Intervalli di confidenza per la media** (e per una proporzione)
- **Verifica di ipotesi sulla media**

Finora abbiamo usato la distribuzione dello stimatore media $\bar{X}_n$ solo per calcolare valore atteso e varianza.
Il TLC ci dà la distribuzione (approssimata) di $\bar{X}_n$: è l'ingrediente che permette di costruire sia gli intervalli di confidenza sia i test.

1 Distribuzione campionaria e TLC

Dove eravamo rimasti

Campione casuale $(X_1, \ldots, X_n)$: variabili i.i.d. con media μ e varianza σ^2. Lo stimatore $\bar{X}_n = \frac{1}{n}\sum_{i=1}^{n} X_i$ ha

$$\mathrm{E}[\bar{X}_n] = \mu \qquad \mathrm{var}(\bar{X}_n) = \frac{\sigma^2}{n}.$$

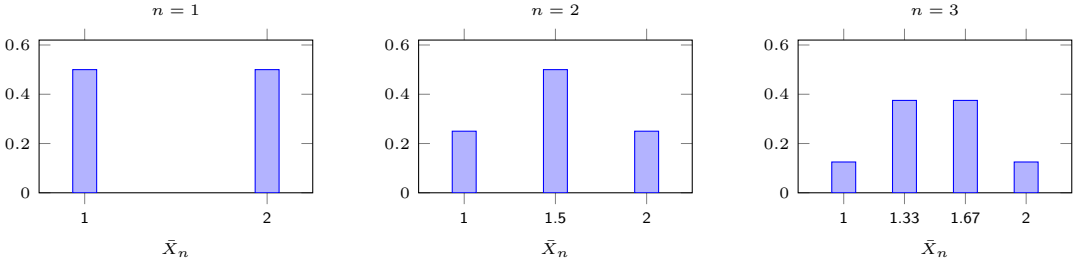
Valore atteso e varianza descrivono *dove* è centrato $\bar{X}_n$ e *quanta* incertezza c'è, ma non bastano per rispondere a domande come:

- qual è un insieme di valori plausibili per μ? (Non solo un singolo valore puntuale, ma un range in cui ci aspettiamo che cada il vero valore del parametro con un certo livello di fiducia)
- uno specifico valore μ_0 è realistico, considerati i dati a nostra disposizione?

Per rispondere serve l'**intera distribuzione di probabilità** di $\bar{X}_n$ (*distribuzione campionaria*).

Riprendiamo l'esempio di una popolazione immaginaria in cui metà della popolazione ha 1 figlio e l'altra metà ha 2 figli. Abbiamo calcolato la distribuzione di $\bar{X}_n$ per $n = 1, 2, 3$. **Che forma ha?**

Distribuzione di $\bar{X}_n$ nell'esempio dei figli



- Il centro resta sempre $\mu = 1.5$, e la dispersione diminuisce.
- La forma comincia a ricordare una campana: qui $n\bar{X}_n$ è (a meno di una traslazione) una binomiale di parametri n e 0.5.
- Succede solo in questo esempio? **No**: è il contenuto del teorema del limite centrale.

Teorema del limite centrale (TLC)

TLC

Siano $X_1, \ldots, X_n$ i.i.d. con media μ e varianza $\sigma^2 < \infty$. Allora, per $n \to \infty$,

$$Z_n = \frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}} \xrightarrow{d} \mathrm{N}(0,1) \qquad \text{cioè} \qquad \mathbb{P}(Z_n \le z) \to \Phi(z) \quad \forall z.$$

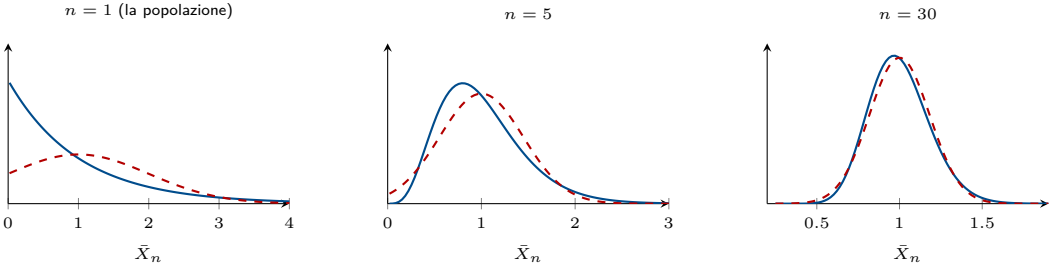
In pratica, per n "abbastanza grande":

$$\bar{X}_n \dot{\sim} \mathrm{N}\left(\mu, \frac{\sigma^2}{n}\right).$$

- Nessuna ipotesi sulla *forma* della distribuzione di X: solo indipendenza, stessa distribuzione e varianza finita.
- Quanto grande deve essere n? Dipende dalla popolazione: più è asimmetrica, più serve n grande (regola pratica: $n \ge 30$ per distribuzioni non troppo asimmetriche).

Esempio sul TLC: popolazione esponenziale

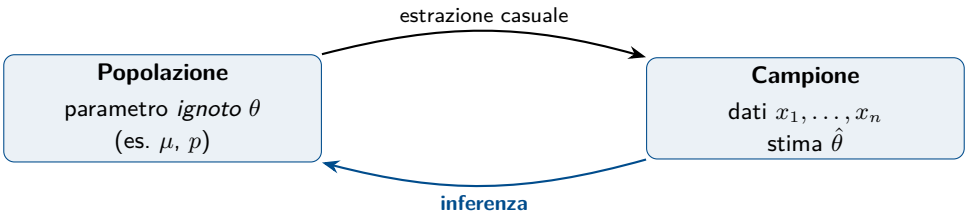
Popolazione molto asimmetrica, $X \sim \mathrm{Exp}(1)$: $\mathrm{E}[X] = \mathrm{var}(X) = 1$.



- Linea continua: distribuzione esatta di $\bar{X}_n$ (per la popolazione esponenziale è una Gamma(n, n)).
  Linea tratteggiata: approssimazione normale $\mathrm{N}(\mu, \sigma^2/n)$.
- Per $n = 1$ la distribuzione è tutt'altro che normale; già per $n = 30$ l'approssimazione è molto buona.

2 Cos'è l'inferenza: intervalli di confidenza e test

Il problema dell'inferenza statistica



Dal campione vogliamo dire qualcosa sulla popolazione, **tenendo conto che il campione è casuale**: un altro campione darebbe un'altra stima. Due domande tipiche:

1. "Quanto vale θ?"

Stima. Oltre al valore più plausibile, vogliamo un *insieme di valori plausibili*.

$\Rightarrow$ **intervallo di confidenza**

2. "Il valore θ_0 è plausibile?"

Decisione. I dati sono compatibili con un'affermazione precisa (es. $\theta = \theta_0$)?

$\Rightarrow$ **verifica di ipotesi (test)**

Perché una stima da sola non basta

Esempio. Sondaggio su $n = 1000$ elettori: otteniamo che il 52% è favorevole a un provvedimento. *La maggioranza è davvero favorevole, o è una casualità che dipende dallo specifico campione?* (Ovvero, un diverso campione potrebbe dare un esito diverso?)

- Stimiamo la probabilità di essere favorevoli come $\hat{p} = 0.52$. Questa però è solo la stima basata su un campione. Un altro campione di 1000 persone potrebbe dare 49%, 54%, ...
- Se la vera proporzione fosse $p = 0.50$ vedremmo comunque $\hat{p} \neq 0.50$ quasi sempre, per puro effetto del caso.
- Un singolo numero **nasconde l'incertezza**: 52% "più o meno quanto"?

Cosa ci serve

- un modo per **quantificare l'incertezza** della stima $\Rightarrow$ intervallo di confidenza;
- una regola per **decidere** se i dati sono compatibili con "$p = 0.50$", cioè se la differenza osservata è solo rumore campionario $\Rightarrow$ test di ipotesi.

Entrambi si costruiscono a partire dalla **distribuzione campionaria** dello stimatore.

Intervallo di confidenza: idea

Invece di comunicare un solo numero, comunichiamo un **intervallo di valori plausibili** per il parametro:

$$\text{stima} \ \pm \ \text{margine d'errore}.$$

Esempio (sondaggio).
0.52 ± 0.031, cioè $[0.489,\ 0.551]$ al livello 0.95.

Il margine d'errore è piccolo quando:

- i dati sono poco variabili (σ piccola);
- il campione è grande (n grande);
- accettiamo meno confidenza (livello più basso).

A cosa serve

- misurare la **precisione** di una stima;
- vedere quali valori del parametro sono **compatibili** con i dati;
- decidere **quanto grande** deve essere il campione.

Nel sondaggio l'intervallo contiene 0.50: con questi dati non possiamo escludere che i favorevoli siano la metà.

Intervallo di confidenza: definizione

Intervallo di confidenza di livello $1-\alpha$

Sia θ il parametro di interesse. Un intervallo di confidenza è $[L, U]$, dove $L = L(X_1, \ldots, X_n)$ e $U = U(X_1, \ldots, X_n)$ sono *statistiche* (dunque variabili casuali) tali che

$$\mathbb{P}\big(L \leq \theta \leq U\big) = 1-\alpha \qquad \text{(almeno a livello approssimato, ovvero } \approx 1-\alpha\text{)}.$$

$1-\alpha$ è il **livello di confidenza** (tipicamente 0.90, 0.95, 0.99).

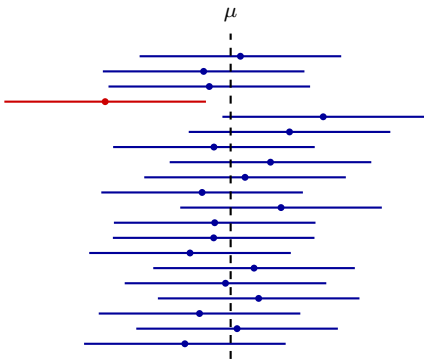
- Gli **estremi sono casuali**, il parametro θ è un numero fisso (ignoto): la probabilità si riferisce al *procedimento* di estrazione del campione.
- Dopo aver osservato i dati si ottiene un intervallo numerico $[l, u]$.

Come si costruisce (idea)

Si parte da una quantità $Q(X_1, \ldots, X_n; \theta)$ la cui distribuzione *non dipende da* θ (es. Z_n, approssimativamente $\mathrm{N}(0,1)$ per il TLC). Si trovano q_1, q_2 con $\mathbb{P}(q_1 \leq Q \leq q_2) = 1-\alpha$ e si *isola* θ nella disuguaglianza.

Come si interpreta un intervallo di confidenza

- μ è un numero fisso (ignoto). A variare, da campione a campione, sono gli **estremi** dell'intervallo.
- Livello 95% significa: **ripetendo** l'estrazione del campione molte volte, circa il 95% degli intervalli così costruiti contiene μ.
- **Errore tipico**: "μ ha probabilità 0.95 di stare in *questo* intervallo". No: una volta calcolato, l'intervallo contiene μ oppure no.
- Più alto il livello, più largo l'intervallo (compromesso tra **confidenza** e **precisione**).



20 campioni $\Rightarrow$ 20 intervalli;

uno non contiene μ (simulazione).

Verifica di ipotesi: idea

Esempio. Lanciamo 100 volte una moneta e otteniamo 62 teste.
Ci chiediamo: *la moneta è equa?* (ipotesi)

Il ragionamento è una sorta di "dimostrazione per assurdo probabilistica":

1. Si ipotizza che la moneta sia equa ($p = 0.5$): *ipotesi nulla* H_0. Ovvero, **si ipotizza che H_0 sia vera**.
2. Si calcola **quanto sarebbe sorprendente, *se* H_0 *fosse vera*, ottenere un risultato lontano da H_0 almeno quanto quello osservato**.
3. Si decide: **se è molto improbabile**, i dati sono difficilmente compatibili con H_0 e la **rifiutiamo**; altrimenti non abbiamo elementi per rifiutarla.

Analogia: il processo penale

L'imputato è presunto innocente (H_0) finché le prove non sono *abbastanza forti* da escludere che sia innocente. Se le prove non bastano, non è dimostrato che sia innocente: semplicemente non è stato condannato perchè non c'erano abbastanza prove a favore della colpevolezza.

Verifica di ipotesi: l'idea con i numeri

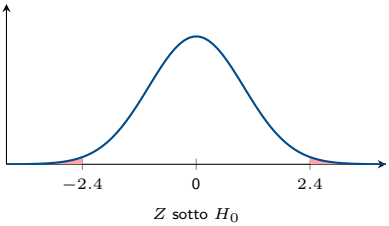
Lanciamo $n = 100$ volte una moneta, osservate 62 teste. La stima che otteniamo è $\hat{p} = \bar{x} = 0.62$.
Ipotesi: moneta equa ($H_0 : \ p = 0.5$).

Sotto H_0, per il TLC, $\bar{X}_n \dot{\sim} \mathrm{N}\big(0.5, \ \frac{0.5 \cdot 0.5}{100}\big)$, con deviazione standard 0.05. Standardizzando:

$$Z_n = \frac{\bar{X}_n - 0.5}{0.05} \dot{\sim} \mathrm{N}(0,1) \quad \text{sotto } H_0$$

e il valore osservato della statistica test è:

$$z_{\text{oss}} = \frac{0.62 - 0.5}{0.05} = 2.4.$$



Area in rosso: *p-value*

$$\alpha^{oss} = 2P_{H_0}(Z_n \geq 2.4) \approx 0.016.$$

Se la moneta fosse equa, uno scostamento così grande (in entrambe le direzioni) capiterebbe solo con probabilità 0.016.

Conclusione: 62 teste è un esito molto sorprendente se la moneta è equa $\implies$ evidenza contro H_0.

Gli ingredienti di un test

1. **Ipotesi.** H_0 (*nulla*: il valore/la situazione di riferimento) contro H_1 (*alternativa*: ciò che vogliamo verificare). Es. $H_0 : \mu = \mu_0$ contro $H_1 : \mu \neq \mu_0$.

2. **Statistica test.** Una funzione $T = T(X_1, \ldots, X_n)$ delle variabili aleatorie che misura la distanza tra i dati e H_0 e la cui distribuzione, *sotto* H_0, è nota (almeno approssimativamente).
   Una volta osservato il campione, si calcola il **valore osservato della statistica test**.

3. **Conclusione**
   a) **p-value.** Probabilità, calcolata sotto H_0, di ottenere un valore della statistica *estremo almeno* quanto quello osservato. Più è piccolo, più i dati sono in contrasto con H_0.
   b) **Livello α fissato.** Si fissa α *prima* di vedere i dati (tipicamente $0.1, 0.05, 0.01$): si ottiene l'intervallo in cui i dati suggeriscono di rifiutare H_0 dato quel livello, detto **regione di rifiuto**. Se il valore osservato della statistica test cade nella regione di rifiuto, si rifiuta H_0.

   - I due modi per concludere un test sono legati, infatti, per un α fissato,

$$\text{si rifiuta } H_0 \iff \alpha^{oss} < \alpha.$$

Errori possibili e cosa significa α

Poiché decidiamo sulla base di un campione casuale, possiamo sbagliare:

	H_0 **vera**	H_0 **falsa**
Non rifiuto H_0	decisione corretta	errore di II tipo (β)
Rifiuto H_0	errore di I tipo (α)	decisione corretta

- $\alpha = \mathbb{P}(\text{rifiutare } H_0 \mid H_0 \text{ vera})$: lo **controlliamo noi**, scegliendolo.
- La **potenza** $(1 - \beta)$ è la probabilità di rifiutare H_0 quando è falsa: cresce con n e con la distanza tra la verità e H_0.
- A parità di n, ridurre α fa aumentare β: non si può rendere piccoli entrambi gli errori senza aumentare il campione.

Come si legge un p-value (e come non si legge)

Cosa è

La probabilità, *supponendo vera* H_0, di osservare dati in contrasto con H_0 almeno quanto quelli che abbiamo.

Piccolo $\Rightarrow$ i dati sono "sorprendenti" se H_0 è vera.

Cosa *non* è

- **Non** è la probabilità che H_0 sia vera.
- **Non** misura la *grandezza* dell'effetto: con n enorme anche differenze irrilevanti danno p-value piccoli.

Attenzione

Non rifiutare H_0 non significa dimostrare che H_0 sia vera: significa solo che i dati non forniscono evidenza sufficiente contro di essa (con n piccolo il test ha poca potenza).

Intervalli di confidenza e test: due strumenti complementari

	Intervallo di confidenza	**Test di ipotesi**
Domanda	Quali valori di θ sono compatibili con i dati?	I dati sono compatibili con $\theta = \theta_0$?
Risposta	Un intervallo $[l, u]$	Sì/no (rifiuto o non rifiuto), più il p-value
Controlla	livello di confidenza $1 - \alpha$	livello di significatività α
Informa su	**grandezza** e precisione dell'effetto	**presenza** di evidenza contro H_0

Legame

Intervalli di confidenza e test di ipotesi sono due facce della stessa procedura: si rifiuta $H_0 : \mu = \mu_0$ al livello α se e solo se μ_0 è fuori dall'intervallo di confidenza di livello $1 - \alpha$. L'intervallo contiene più informazione, perché mostra *tutti* i valori non rifiutabili.

Ora applichiamo queste idee al caso della **media**, usando il TLC.

3 Intervalli di confidenza per la media

Applichiamo la ricetta alla media. Usiamo il TLC (per ora σ nota): la quantità $Z_n = \frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}} \dot{\sim} \mathrm{N}(0,1)$ non dipende da μ, quindi

$$P\left(-z_{1-\alpha/2} \leq \frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}} \leq z_{1-\alpha/2}\right) \approx 1-\alpha.$$

Isolando μ nella disuguaglianza:

$$P\left(\bar{X}_n - z_{1-\alpha/2}\frac{\sigma}{\sqrt{n}} \leq \mu \leq \bar{X}_n + z_{1-\alpha/2}\frac{\sigma}{\sqrt{n}}\right) \approx 1-\alpha.$$

Intervallo di confidenza di livello $1-\alpha$ per μ

$$IC_{1-\alpha}(\mu) = \left[\bar{X}_n - z_{1-\alpha/2}\frac{\sigma}{\sqrt{n}},\ \bar{X}_n + z_{1-\alpha/2}\frac{\sigma}{\sqrt{n}}\right] = \bar{X}_n \pm z_{1-\alpha/2}\cdot \mathrm{SE}$$

Struttura: **stima** $\pm$ **quantile** $\times$ **errore standard**. È la forma che ritroveremo per molti altri parametri.

Se σ non è nota

In pratica σ è ignota: la sostituiamo con $S_c = \sqrt{S_c^2}$ (consistente per σ). Per n grande

$$\frac{\bar{X}_n - \mu}{S_c/\sqrt{n}} \dot{\sim} \mathrm{N}(0,1)$$

(lo garantisce il TLC insieme al fatto che $S_c/\sigma \to 1$). Quindi

$$IC_{1-\alpha}(\mu) = \bar{X}_n \pm z_{1-\alpha/2} \frac{S_c}{\sqrt{n}}.$$

Esempio: altezza media

Campione casuale di $n = 100$ persone: $\bar{X}_n = 171.2$ cm, $s_c = 9.5$ cm.

- Stima dell'errore standard: $\widehat{\mathrm{SE}} = \dfrac{9.5}{\sqrt{100}} = 0.95$ cm
- IC al 95%:

$$171.2 \pm 1.96 \times 0.95 = 171.2 \pm 1.86 \implies [169.34,\ 173.06]$$

- IC al 99%:

$$171.2 \pm 2.576 \times 0.95 = 171.2 \pm 2.45 \implies [168.75,\ 173.65]$$

Interpretazione

I dati sono compatibili con valori di μ tra circa 169.3 e 173.1 cm; valori fuori da questo intervallo sono poco plausibili al livello 95%. Notare che l'intervallo al 99% è più largo.

Intervallo di confidenza per una proporzione

Popolazione con una caratteristica presente in una frazione p di unità. Sia $X_i = 1$ se l'i-esima unità ha la caratteristica, 0 altrimenti:

$$X_i \sim \text{Bernoulli}(p) \qquad \mu = p, \;\; \sigma^2 = p(1-p).$$

Lo stimatore di p è $\bar{X}_n$, la *proporzione campionaria*: il TLC si applica direttamente (anche qui, stimiamo la varianza, non nota),

$$\bar{X}_n \dot{\sim} \text{N}\Big(p, \frac{p(1-p)}{n}\Big) \implies \bar{X}_n \dot{\sim} \text{N}\Big(p, \frac{\bar{X}_n(1-\bar{X}_n)}{n}\Big)$$

otteniamo

$$IC_{1-\alpha}(p) = \bar{X}_n \pm z_{1-\alpha/2}\sqrt{\frac{\bar{X}_n(1-\bar{X}_n)}{n}}.$$

Esempio. In un campione di $n = 400$ persone, 252 sono favorevoli a un provvedimento.

- $\hat{p} = \bar{x} = 252/400 = 0.63$, $\widehat{\text{SE}} = \sqrt{0.63 \times 0.37/400} \approx 0.0241$
- IC al 95%: $0.63 \pm 1.96 \times 0.0241 \;\Rightarrow\; [0.583,\; 0.677]$

L'approssimazione è affidabile se $n\hat{p}$ e $n(1-\hat{p})$ sono entrambi abbastanza grandi (almeno circa 10).

Quanto deve essere grande il campione?

L'ampiezza dell'intervallo è $2z_{1-\alpha/2}\,\sigma/\sqrt{n}$: dipende da n attraverso $\sqrt{n}$.

- Per **dimezzare** l'ampiezza serve **quadruplicare** n.
- Se vogliamo un margine d'errore massimo e (semi-ampiezza $\leq e$):

$$z_{1-\alpha/2}\frac{\sigma}{\sqrt{n}} \leq e \iff n \geq \left(\frac{z_{1-\alpha/2}\,\sigma}{e}\right)^2.$$

Esempio (altezza). $\sigma \approx 10$ cm (valore guida, da dati precedenti), livello 95%, margine $e = 1$ cm:

$$n \geq \left(\frac{1.96 \times 10}{1}\right)^2 = 384.16 \;\Rightarrow\; n = 385.$$

Esempio (proporzione). Caso peggiore $p = 0.5$, margine $e = 0.03$, livello 95%:

$$n \geq \frac{1.96^2 \times 0.25}{0.03^2} \approx 1068.$$

4 Verifica di ipotesi sulla media

Test sulla media: applichiamo gli ingredienti

Vogliamo valutare se i dati sono compatibili con un valore specifico μ_0:

$$H_0 : \mu = \mu_0 \qquad \text{contro} \qquad H_1 : \mu \neq \mu_0.$$

1. **Statistica test.** Se H_0 è vera, per il TLC

$$Z = \frac{\bar{X}_n - \mu_0}{S_c/\sqrt{n}} \dot{\sim} \mathrm{N}(0,1) \quad \text{sotto } H_0.$$

   Un valore osservato z_{oss} lontano da 0 è poco plausibile sotto H_0.

2. **p-value.**

$$\alpha^{oss} = \mathbb{P}_{H_0}\big(|Z| \geq |z_{\text{oss}}|\big) = 2\big(1 - \Phi(|z_{\text{oss}}|)\big) \quad \text{(approssimato)}.$$

3. **Decisione.** Si rifiuta H_0 al livello α se $\alpha^{oss} < \alpha$, equivalentemente se $|z_{\text{oss}}| > z_{1-\alpha/2}$. In tal caso la probabilità di rifiutare H_0 quando è vera (errore di primo tipo) è circa α.

Esempio e legame con l'intervallo di confidenza

Stessi dati dell'altezza: $n = 100$, $\bar{X}_n = 171.2$, $s_c = 9.5$. Testiamo $H_0 : \mu = 170$ contro $H_1 : \mu \neq 170$.

$$z_{\text{oss}} = \frac{171.2 - 170}{9.5/\sqrt{100}} = \frac{1.2}{0.95} \approx 1.26 \qquad \alpha^{oss} \approx 2 \times (1 - 0.897) \approx 0.21.$$

Poiché $\alpha^{oss} > 0.05$ (equivalentemente $1.26 < 1.96$), **non rifiutiamo** H_0 al livello 5%.

Dualità test–intervallo

Il test di livello α rifiuta $H_0 : \mu = \mu_0$ contro $H_1 : \mu \neq \mu_0$ se e solo se μ_0 *non* appartiene all'intervallo di confidenza di livello $1 - \alpha$.

Qui $\mu_0 = 170 \in [169.34,\ 173.06]$: coerente col risultato del test.

Riassunto

- Il **TLC** dà la distribuzione approssimata di $\bar{X}_n$: $\bar{X}_n \dot{\sim} \mathrm{N}(\mu, \sigma^2/n)$, qualunque sia la popolazione (con varianza finita).
- L'**inferenza** usa il campione per rispondere a due domande sul parametro:
  - *quali valori sono plausibili?* $\Rightarrow$ **intervallo di confidenza** $\bar{X}_n \pm z_{1-\alpha/2}\,\widehat{\mathrm{SE}}$;
  - *è compatibile con* μ_0*?* $\Rightarrow$ **test**: $Z = (\bar{X}_n - \mu_0)/\widehat{\mathrm{SE}} \dot{\sim} \mathrm{N}(0,1)$ sotto H_0, si rifiuta se $\alpha^{oss} < \alpha$.
- I due strumenti sono legati dalla **dualità**: μ_0 fuori dall'IC al $1-\alpha$ $\iff$ H_0 rifiutata al livello α.
- Tutto questo funziona bene per la media (e le proporzioni), grazie al TLC.

Prossimo passo

Come costruire stimatori e fare inferenza in modo generale, per qualunque modello e parametro? $\Rightarrow$ **inferenza di verosimiglianza**.